

# Documentação


**Nome: Marco Túlio Machado França**

**Prática: Utilizar algoritmo LZ78 para comprimir arquivos.**

## Parte 1:

Primeiramente tive que entender o algoritmo. Seguindo o link: <https://pt.wikipedia.org/wiki/LZ78>  
Fiz algumas anotações:

$D_{seq} = \text{Cód do Pai}$



A árvore de prefixos ficaria nesse formato. Além disso é importante saber que a cadeia que é salva contém o código do nó pai.

Então, por exemplo, quando o sétimo caractere "A" é adicionado, a saída é (3,'A') exatamente para termos o mapeamento do pai desse caractere e poder trabalhar para reconstruir a string.

Dado isso parti para a construção do código

## Parte 2:

Eu não tinha familiaridade com python. Até o momento, praticamente tudo que fiz na faculdade foi em c++, mas por ser uma linguagem bem mais simples que c++, por mais que seja tudo novo, decidi fazer em python, e valeu a pena.

Primeiramente trabalhei com a parte de como receber as entradas da linha de comando, depois leitura e escrita em arquivos e por fim, de fato a implementação dos algoritmos.

Utilizando a ideia do algoritmo e a sugestão do professor, criei uma função para varrer o arquivo uma vez, já inserir na trie e verificar quando bytes seriam necessários para armazenar todos os inteiros. Então, por exemplo, se  $D_{seq} = 1000$ , que é maior  $2^8$  e menor que  $2^{16}$ , seriam necessários 2 bytes para salvar os inteiros que representam os códigos dos nós.

Com essa ideia já deu para comprimir bem os arquivos. Então, depois de passar uma vez verificando, eu zero a trie e crio novamente, agora escrevendo no arquivo binário. Tive problemas ao converter caracteres que tinham tamanho em bytes maior que 1, apareceram só de 2 e 3 bytes, e a estratégia que utilizei para driblar essa situação foi, toda vez que encontrar um caractere que em bytes terá tamanho igual 2 vou inserir o caractere ~ (til) e se o tamanho for igual a 3, inserir ^ (circunflexo) no arquivo binário antes de inserir o caractere. Assim, na hora de descomprimir o código, sempre que encontrar um dos dois caracteres saberemos quantos bytes teremos que ler. Utilizei esses dois caracteres pois é muito improvável de tê-los em um texto sozinhos. Em todos os testes que fiz deu certo.

O trabalho ficou com três arquivos .py, a main.py que tem a parte de tratar a entrada do terminal e executar o programa em si. Trie.py que tem a estrutura para compactar o arquivo e as funções que precisei implementar para tratar o texto. E, finalmente, o arquivo descomprimir.py, onde coloquei algumas funções que precisei utilizar para descomprimir o arquivo .z78.

**Parte 3:**

Feito o algoritmo criei alguns cenários de teste além dos que o professor já havia fornecido. Os resultados foram os seguintes:

	tamanho .txt (KB)	tamanho .z78 (KB)	Taxa de Compressão
Ex01	95,5	61,2	35,92%
Ex02	102	66,3	35,00%
Ex03	43,9	27,9	36,45%
Ex04	190	91,3	51,95%
Ex05	222	116	47,75%
Ex06	147	82,6	43,81%
Ex07	169	98,8	41,54%
Ex08	1930	1447	25,03%
Ex09	1962	1465	25,33%
Ex10	1666	1282	23,05%

**Conclusão:**

O trabalho foi uma excelente oportunidade de concretizar os conhecimentos teóricos e de aprender novas tecnologias. Foi interessante entender como funciona a compressão de arquivos, não só por conta de usar um algoritmo que ajude a comprimir como é o caso do LZ78 mas também de ter que escrever os arquivos binários e ter que tratar, dependendo do tamanho dos bytes no caso dos caracteres.